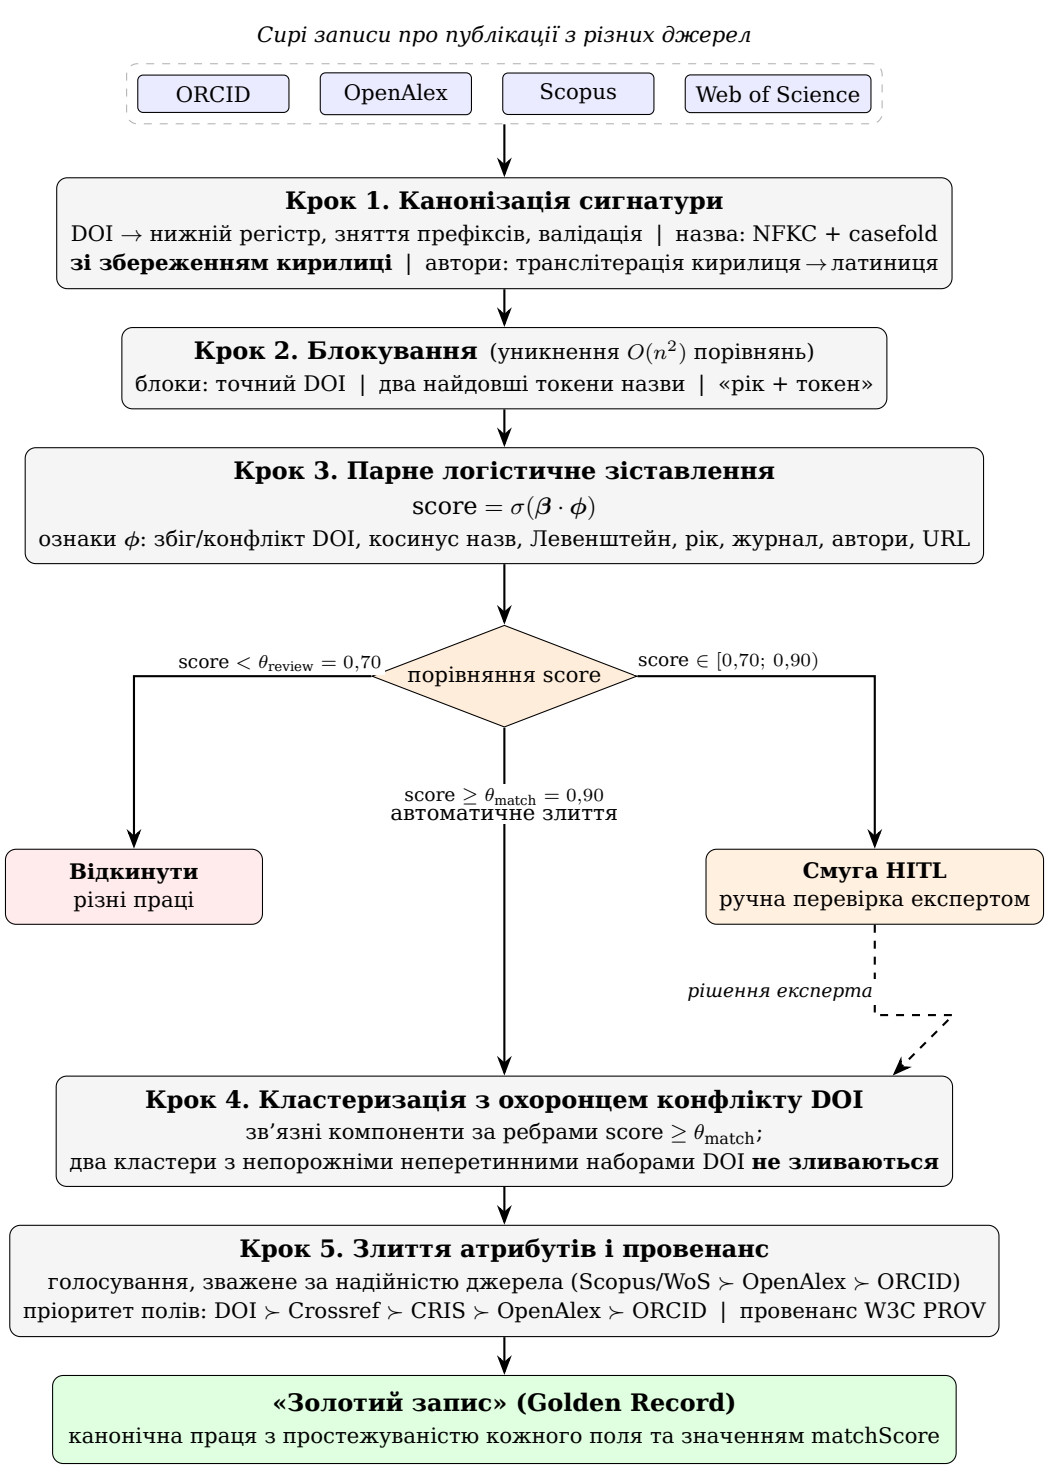
Сирі записи про публікації з різних джерел
ORCID
OpenAlex
Scopus
Web of Science
Крок 1. Канонізація сигнатури
DOI → нижній регістр, зняття префіксів, валідація | назва: NFKC + casefold
зі збереженням кирилиці | автори: транслітерація кирилиця → латиниця
Крок 2. Блокування (уникнення $O(n^2)$ порівнянь)
блоки: точний DOI | два найдовші токени назви | «рік + токен»
Крок 3. Парне логістичне зіставлення
score $= \sigma(\boldsymbol{\beta} \cdot \boldsymbol{\phi})$
ознаки ϕ: збіг/конфлікт DOI, косинус назв, Левенштейн, рік, журнал, автори, URL
порівняння score
score $< \theta_{\text{review}} = 0{,}70$
score $\in [0{,}70;\ 0{,}90)$
score $\geq \theta_{\text{match}} = 0{,}90$
автоматичне злиття
Відкинути
різні праці
Смуга HITL
ручна перевірка експертом
рішення експерта
Крок 4. Кластеризація з охоронцем конфлікту DOI
зв'язні компоненти за ребрами score $\geq \theta_{\text{match}}$;
два кластери з непорожніми неперетинними наборами DOI не зливаються
Крок 5. Злиття атрибутів і провенанс
голосування, зважене за надійністю джерела (Scopus/WoS ≻ OpenAlex ≻ ORCID)
пріоритет полів: DOI ≻ Crossref ≻ CRIS ≻ OpenAlex ≻ ORCID | провенанс W3C PROV
«Золотий запис» (Golden Record)
канонічна праця з простежуваністю кожного поля та значенням matchScore