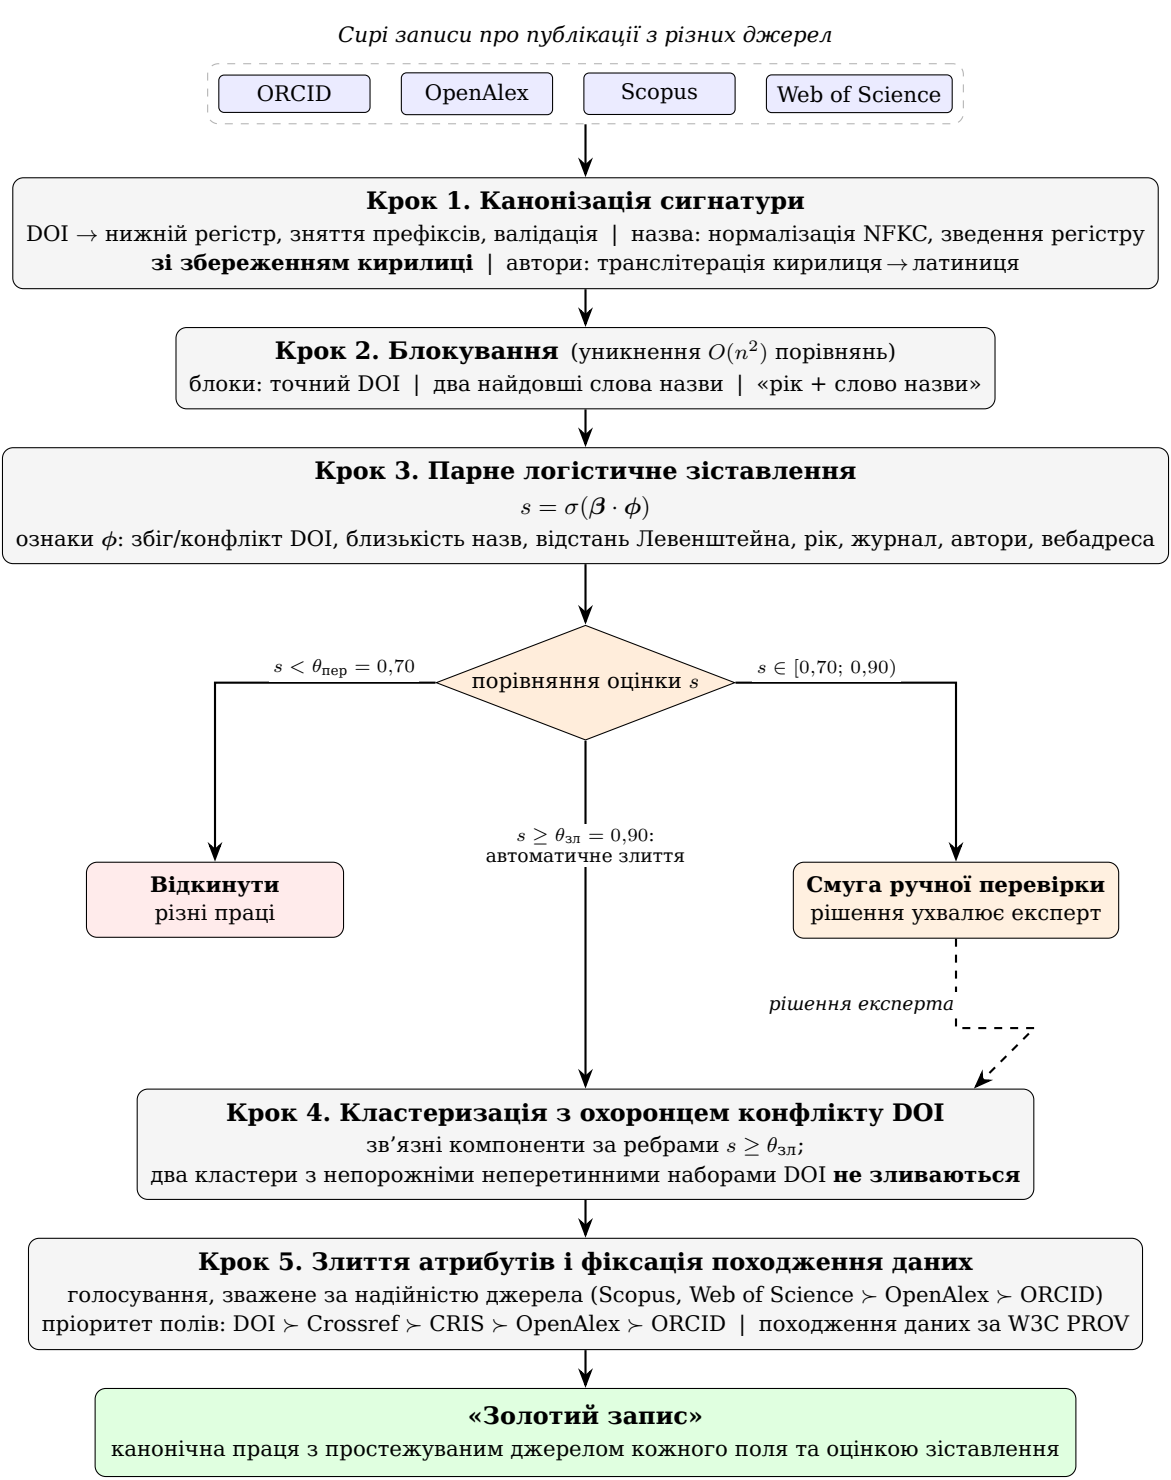
Сирі записи про публікації з різних джерел
ORCID
OpenAlex
Scopus
Web of Science
Крок 1. Канонізація сигнатури
DOI → нижній регістр, зняття префіксів, валідація | назва: нормалізація NFKC, зведення регістру зі збереженням кирилиці | автори: транслітерація кирилиця → латиниця
Крок 2. Блокування (уникнення $O(n^2)$ порівнянь)
блоки: точний DOI | два найдовші слова назви | «рік + слово назви»
Крок 3. Парне логістичне зіставлення
$s = \sigma(\boldsymbol{\beta} \cdot \boldsymbol{\phi})$
ознаки ϕ: збіг/конфлікт DOI, близькість назв, відстань Левенштейна, рік, журнал, автори, вебадреса
порівняння оцінки s
$s < \theta_{\text{пер}} = 0{,}70$
$s \in [0{,}70;\ 0{,}90)$
$s \geq \theta_{\text{зл}} = 0{,}90$: автоматичне злиття
Відкинути
різні праці
Смуга ручної перевірки
рішення ухвалює експерт
рішення експерта
Крок 4. Кластеризація з охоронцем конфлікту DOI
зв'язні компоненти за ребрами $s \geq \theta_{\text{зл}}$;
два кластери з непорожніми неперетинними наборами DOI не зливаються
Крок 5. Злиття атрибутів і фіксація походження даних
голосування, зважене за надійністю джерела (Scopus, Web of Science ≻ OpenAlex ≻ ORCID)
пріоритет полів: DOI ≻ Crossref ≻ CRIS ≻ OpenAlex ≻ ORCID | походження даних за W3C PROV
«Золотий запис»
канонічна праця з простежуваним джерелом кожного поля та оцінкою зіставлення